

— 2교시

필요한 것만 남기기

데이터 조회와 전처리 — 무엇을 버릴지 내가 정합니다

2.1

분석의 절차와, 이 시간의 위치

1교시에 데이터를 열었고, 결측치(비어 있는 값)가 있다는 것을 발견했습니다

문제
정의

데이터
이해

전처리

집계·비교

탐색
(EDA)

시각화

통계
검정

결론·보고

이 단계에서 던지는 질문 — “이 결측치는 왜 생겼는가”

이 시간이 끝나면

전처리는 데이터를 “깨끗하게 만드는” 작업이 아닙니다

- 1 원하는 행과 열만 골라낼 수 있다
- 2 조건에 맞는 데이터만 걸러낼 수 있다
- 3 결측치·중복값·형식 오류를 처리할 수 있다
- 4 처리 방법을 바꾸면 결론이 달라진다는 것을 안다

전처리는 **무엇을 버릴지 정하는 작업**입니다. 무엇을 버렸느냐에 따라 나중에 나오는 숫자가 달라집니다.

2.2

전처리란 무엇인가

전처리(preprocessing)란 받은 데이터를 분석할 수 있는 상태로 만드는 일이다.

흔한 오해

데이터를 “깨끗하게” 만드는 기계적인 작업.
정해진 정답이 있어서 그대로 따라 하면 되는 일.

실제

무엇을 버릴지 정하는 판단.
무엇을 버렸느냐에 따라 뒤에 나오는 숫자가 달라진다.

실무에서 분석 시간의 **절반 이상이 이 단계에** 들어간다. 그리고 이 단계의 선택은 대부분 기록으로 남기지 않으면 아무도 모른다.

2.3

데이터가 문제를 일으키는 네 가지 방식

missing values

id	val	cat
A	10	X
B		X
C	30	Y
D		Z

duplicate rows

id	val	cat
A	10	X
B	20	Y
B	20	Y
C	30	Z

왼쪽 = 결측치 · 오른쪽 = 중복행. 둘 다 눈으로는 잘 보이지 않는다

이름

무엇인가

예

결측치
missing value

값이 비어 있는 칸

배송일이 기록되지 않은 주문

이상치
outlier

다른 값에 비해 유난히 크거나 작은 값

단가가 0원인 주문

중복값
duplicate

같은 내용이 두 번 이상 들어간 행

같은 주문이 두 번 저장됨

형식 오류
type error

자료형이 잘못 읽힌 값

숫자·날짜가 글자로 저장됨



골라내고 걸러내는 도구

엑셀에서 필터 걸고 정렬하던 일이 그대로 있습니다. 이름만 다릅니다

엑셀에서 하던 일	Pandas 에서 부르는 이름
필요한 열만 보기	열 선택
필요 없는 열 숨기기	열 버리기 (drop)
자동 필터로 조건 걸기	조건 필터
조건 여러 개 걸기	그리고 · 또는 로 조건 잇기
정렬	정렬 (sort)

코드를 외울 필요는 없습니다. 하고 싶은 일에 이름을 붙일 수 있으면 코드는 검색하거나 물어보면 나옵니다. 노트북에 전부 적혀 있으니 오늘은 따라 실행해 보시면 됩니다.

2.4

결측치 — 값이 비어 있는 칸

먼저 물어야 할 것은 “어떻게 지울까”가 아니라 “왜 비었을까” 다. 이유에 따라 처리가 달라진다.

비어 있는 이유	예	어떻게 볼 것인가
무작위로 빠짐	입력 실수, 시스템 오류	지워도 결과가 크게 바뀌지 않는다
한쪽에 몰려 빠짐	취소 건에만 배송일이 없음	지우면 그 집단이 통째로 빠진다
없는 것이 정상	비회원 주문의 회원번호	비어 있다는 사실 자체가 정보다

두 번째가 가장 위험하다. 지워도 오류가 나지 않고 표도 멀쩡해 보이지만, **결과 숫자가 조용히 바뀐다.**

결측치를 만나면 셋 중 하나를 고른다

방법	언제 그렇게 하나
버린다	결측치가 무작위로 흩어져 있고, 양이 적을 때
채운다	무엇으로 채울지 근거가 있을 때 (평균 · 직전 값 · 0)
표시한다	비어 있다는 사실 자체가 정보일 때 — 비었다는 표시를 새 열로 남긴다

빈 칸을 습관적으로 0으로 채우는 것이 가장 위험하다. 비어 있는 것과 0은 다르다. 매출이 “없는 것”과 “0원인 것”은 완전히 다른 이야기다.

어느 쪽을 골랐든 무엇을 몇 건 버렸는지 적어 둔다.

2.6

중복값 — 무엇이 진짜 중복인가

지워야 할 중복은 **모든 칸이 똑같은 행**뿐이다. 특정 열의 값이 반복되는 것은 대개 중복이 아니다.

중복이 아닌 것

한 주문에 물건을 여럿 담으면 **주문번호가 반복**된다.
주문번호로 지우면 **다른 품목이 통째로 사라진다**.

중복인 것

모든 열의 값이 똑같은 행.
먼저 몇 개인지 세어 보고 지운다.

순서도 중요하다 — **중복을 지운 뒤에 집계해야** 같은 자료가 두 번 더해지지 않는다.

형식 오류 — 숫자와 날짜가 글자로 읽힐 때

엑셀에서 숫자가 왼쪽으로 붙고 SUM 이 0으로 나오던 그 상황이다. 자료형이 잘못 읽히면 계산 자체가 되지 않는다.

무엇이 안 되나	글자로 읽히면
더하기	두 값이 이어 붙는다 — 1500 + 900 이 1500900 이 된다
크기 비교	사전 순으로 비교된다 — "9" 가 "100" 보다 크다
기간 계산	날짜끼리 뺄 수 없다
연 · 월 추출	월별로 묶는 일이 되지 않는다

바꿀 수 없는 값을 결측치로 넘기면 결측치가 여기서 새로 생긴다.

이 시간에 다루는 것

노트북에서 하나씩 실행해 본다. 지금 외우지 않아도 된다

하는 일	쓰는 것
열 고르기 · 버리기	<code>df[['열1', '열2']]</code> · <code>.drop()</code>
조건으로 거르기	<code>df[df['열'] > 값]</code>
조건 여러 개	<code>&</code> 그리고 · <code> </code> 또는
여러 값 · 범위 · 글자	<code>.isin()</code> · <code>.between()</code> · <code>.str.contains()</code>
정렬	<code>.sort_values()</code>
결측치 세기 · 버리기 · 채우기	<code>.isna().sum()</code> · <code>.dropna()</code> · <code>.fillna()</code>
중복 세기 · 지우기	<code>.duplicated().sum()</code> · <code>.drop_duplicates()</code>
자료형 바꾸기 · 날짜 조각	<code>.astype()</code> · <code>.dt.year</code> · <code>.dt.month</code>

— 이제 손으로 합니다

노트북 2교시를 엽니다

열 선택 → 조건 필터 → 결측치 원인 파악 → 전처리 기록 남기기