

— 3교시

여러 표를 합쳐 요약합니다

데이터 결합과 집계 — 엑셀의 피벗테이블과 VLOOKUP에 해당하는 시간입니다

3.1

분석의 절차와, 이 시간의 위치

이 시간은 네 번째 단계에 해당한다. 정리한 데이터를 묶고 합쳐 요약한다

문제
정의

데이터
이해

전처리

집계·비교

탐색
(EDA)

시각화

통계
검정

결론·보고

이 단계에서 던지는 질문 — “무엇과 비교할 것인가”

이 시간이 끝나면

함수 이름을 외우는 것이 목표가 아닙니다

- 1 항목별로 묶어서 합계·평균을 낼 수 있다
- 2 두 개의 표를 하나로 이어 붙일 수 있다
- 3 비교 기준을 바꿔 가며 볼 수 있다
- 4 **같은 데이터로 정반대 결론이 나올 수 있다는 것을 안다**

“이번 분기 매출은 3억입니다”

회의에서 이 보고를 들었습니다. 무슨 생각이 드십니까?

아무 생각도 들지 않는 것이 정상입니다. 좋은 건지 나쁜 건지 알 수 없기 때문입니다.

지난 분기가 2억이었다면

좋은 소식

지난 분기가 5억이었다면

나쁜 소식

목표가 4억이었다면


미달

숫자 하나만으로는 판단할 수 없습니다. **무언가와 견주어야 의미가 생깁니다.**

3.2

집계와 결합이란 무엇인가

1만 행을 그대로 볼 수는 없다. **집계**는 행을 묶어 줄이는 일이고, **결합**은 흩어진 표를 옆으로 붙이는 일이다.



집계 — 같은 값끼리 묶어 하나의 숫자로 줄인다

집계 (aggregation)

행을 묶어 **하나의 숫자로 줄인다**

엑셀의 피벗테이블

결합 (join)

두 표를 공통 열로 **옆에 붙인다**

엑셀의 VLOOKUP

3.3


집계는 세 자리를 정하는 일이다

정할 것	묻는 것	예
① 묶을 기준	무엇별로 볼 것인가	지역별 · 품목별 · 월별
② 요약할 값	어떤 숫자를 볼 것인가	매출 · 이익 · 수량
③ 계산 방법	어떻게 줄일 것인가	합계 · 평균 · 개수

세 자리 중 하나만 바뀌도 결론이 달라진다. 같은 데이터에서 매출을 요약하면 잘 나가는 품목이고, 이익을 요약하면 적자 품목일 수 있다.

3.4

묶어서 계산하기



같은 값끼리 묶어 하나의 행으로 줄인다

엑셀 피벗의 **행 영역 · 값 영역 · 값 요약 기준** 과 같습니다.

3.5

무엇을 계산하느냐가 결론을 정한다

매출로 묶으면

“효자 품목입니다”


이익으로 묶으면

“남는 게 없습니다”

같은 표, 같은 묶음. **계산할 값만 바꿨습니다.**

3.6

교차표 — 두 기준을 겹쳐야 보이는 것



한 기준으로만 묶으면 부산의 적자가 전자 이익에 묻힌다

한 기준으로만 묶으면 **다른 쪽 숫자에 가려집니다.**

3.7


기준선 — 무엇과 견줄 것인가

기준선	주의할 점
전월 대비	계절 영향을 그대로 받는다
전년 동월 대비	계절 영향이 상쇄된다
목표 대비	목표를 어떻게 세웠는지에 달려 있다
누적 대비	월별 등락이 가려진다

“매출이 늘었다”가 아니라 **“무엇 대비 얼마 늘었다”**

Join(결합)—무엇을 남길 것인가

양쪽에 다 있는 열(키)을 기준으로 붙입니다



색칠한 부분이 결과에 남는다

'left'	왼쪽 표는 전부 — 엑셀 VLOOKUP
'inner'	양쪽 다 있는 것만
'outer'	양쪽 전부

붙이면 실제로 이렇게 됩니다

orders		returns		how='left'		
id	sales	id	ret	id	sales	ret
101	12	101	Y	101	12	Y
102	30	103	Y	102	30	—
103	8	104	Y	103	8	Y

how='inner'			how='outer'		
id	sales	ret	id	sales	ret
101	12	Y	101	12	Y
103	8	Y	102	30	—
			103	8	Y
			104	—	Y

왼쪽 두 표를 id 로 붙인 결과. 색칠한 칸이 결측치

오른쪽 표에 없던 행은 **결측치가 됩니다.**

3.10

붙인 뒤 확인할 것

확인	어긋나면
행 수가 그대로인가	키가 중복되면 행이 붙어난다
안 붙은 행이 얼마나 되나	없던 행은 결측치가 된다
키의 형식이 같은가	숫자 · 글자가 섞이면 하나도 안 붙는다

붙여서 나온 차이를 곧바로 원인으로 읽지 않습니다. 지금 아는 것은 **숫자가 다르다는 사실** 뿐입니다.

이 시간에 다루는 것

노트북에서 하나씩 실행해 본다. 지금 외우지 않아도 된다

하는 일	쓰는 것
묶어서 합계 · 평균 · 개수	<code>.groupby('열')['값'].sum()</code>
여러 계산 한 번에	<code>.agg(['sum', 'mean'])</code>
이름 붙여 여러 열	<code>.agg(이름=('열', 'sum'))</code>
두 기준으로 교차	<code>.pivot_table(index=, columns=, values=)</code>
두 표 붙이기	<code>pd.merge(A, B, on='키', how='left')</code>
월 단위로 묶기	<code>.dt.to_period('M') · .resample('ME')</code>
전월 대비 변화율	<code>.pct_change()</code>

— 이제 손으로 합니다

노트북 3교시를 엽니다

묵기 → 교차 → 기준 바꿔 보기 → 붙이기 → 두 개의 보고서