

— 3교시 정리

데이터 결합과 집계

이 시간에 쓴 코드와 실행 결과

3.1

묶어서 계산하기

형식

df.groupby(' 묶을 열 ')['값 열 '].계산()

예제

df.groupby('Region')['Sales'].sum().round(0)

계산	기능
.sum()	합계
.mean()	평균
.count()	개수
.nunique()	값 종류 수

실행 결과

Region

Central508541.0

East805219.0

South393544.0

West743434.0

Name: Sales, dtype: float64

3.2

여러 계산 한 번에

형식

```
df.groupby('열')['값'].agg(['sum', 'mean'])
df.groupby('열').agg(이름=('값열', 'sum'), 이름2=('값열2', 'nunique'))
```

예제

```
df.groupby('Category')['Profit'] \
    .agg(['sum', 'mean']).round(2)
```

실행 결과

	sum	mean
Category		
Furniture	20109.04	9.10
Office Supplies	125296.35	20.35
Technology	147489.05	78.79

Furniture 는 합계로는 이익이 나지만 **건당 평균은 9.10** 으로 가장 낮다. 같은 데이터도 계산 방법에 따라 다르게 읽힌다.

3.3

이름 붙여 집계하기

예제

```
df.groupby('Region').agg(  
    sales=('Sales', 'sum'),  
    orders=('Order ID', 'nunique')  
)
```

한 번에 여러 열을 만들고 **결과 열 이름까지 지정**할 수 있다.

실행 결과

	sales	orders
Region		
Central	508541.0	1179
East	805219.0	1475
South	393544.0	822
West	743434.0	1635

행 수가 아니라 **주문 수**를 세려면 `nunique` 를 쓴다.

3.4

두 기준으로 교차하기

형식

```
df.pivot_table(index='행기준', columns='열기준', values='값', aggfunc='sum')
```

예제

```
df.pivot_table(index='Category',
                columns='Region',
                values='Profit',
                aggfunc='sum').round(0)
```

실행 결과

Region	Central	East	South	West
Category				
Furniture	-2574.0	3445.0	6622.0	12616.0
Office Supplies	8975.0	43211.0	18955.0	54154.0
Technology	33917.0	49035.0	20041.0	44496.0

Central 의 Furniture 만 적자(-2,574) 다. 지역별로만 봐도, 품목별로만 봐도 보이지 않는다. 두 기준을 교차해야 나타난다.

3.5

두 표 붙이기

형식

```
pd.merge(왼쪽 표, 오른쪽 표, on='키열', how='left')
```

예제

```
returns = pd.read_csv('superstore_returns.csv')

m = pd.merge(df, returns,
              on='Order ID', how='left')
print(m.shape)
print(m['Returned'].notna().sum())
```

실행 결과

```
(10239, 22)
806
```

행 수는 10,239 그대로이고 **열이 하나 늘었다**. 붙인 뒤에는 항상 행 수를 확인한다.
키가 중복되면 행이 붙어난다.

3.6

결합 방식

how=	무엇을 남기나	언제 쓰나
'left'	왼쪽 표의 행을 모두	기준 표에 정보를 덧붙일 때 — 대부분 이것
'inner'	양쪽에 다 있는 행만	둘 다 있는 것만 볼 때
'outer'	양쪽 행을 모두	어느 쪽에만 있는지 확인할 때

| how='left' 에서 오른쪽 표에 없는 행은 **결측치**가 된다. 위 예제에서 반품 기록이 없는 주문의 **Returned** 가 비는 것이 그것이다.

3.7

기간으로 묶기

형식

```
df.set_index('날짜열')['값'].resample('ME').sum()    → 월별 합계
series.pct_change()                                → 직전 대비 변화율
```

예제

```
m = df.set_index('Order Date')['Sales'] \
      .resample('ME').sum()
print(m.pct_change().mul(100).round(1).head(4))
```

실행 결과

Order Date	
2023-01-31	NaN
2023-02-28	-69.1
2023-03-31	1159.6
2023-04-30	-50.3

첫 달은 비교 대상이 없으므로 NaN 이다.

한 장 정리

<code>.groupby('열')['값'].sum()</code>	묶어서 합계
<code>.mean()</code> · <code>.count()</code> · <code>.nunique()</code>	평균 · 개수 · 값 종류 수
<code>.agg(['sum', 'mean'])</code>	여러 계산 한 번에
<code>.agg(이름=('열', 'sum'))</code>	이름 붙여 집계
<code>.pivot_table(index=, columns=, values=)</code>	두 기준 교차
<code>pd.merge(A, B, on='키', how='left')</code>	두 표 붙이기
<code>.resample('ME').sum()</code>	월별로 묶기
<code>.pct_change()</code>	직전 대비 변화율