

— 4교시

그 평균, 믿어도 됩니까

데이터 탐색과 정리 — 요약한 숫자를 의심해 보는 시간

4.1

분석의 절차와, 이 시간의 위치

이 시간은 다섯 번째 단계에 해당한다. 요약한 숫자를 되짚어 본다

문제
정의

데이터
이해

전처리

집계·비교

탐색
(EDA)

시각화

통계
검정

결론·보고

이 단계에서 던지는 질문 — “이 평균을 믿어도 되는가”

이 시간이 끝나면

3교시까지 계속 합계와 평균을 냈습니다. 이번에는 그 숫자를 되짚어 봅니다

- 1 평균과 중앙값이 왜 다른지 설명할 수 있다
- 2 분포를 그려 보고 데이터의 모양을 확인할 수 있다
- 3 표준편차가 무엇을 말해 주는지 안다
- 4 이상치를 찾고, 지울지 남길지 스스로 판단할 수 있다

4.2

탐색적 데이터 분석(EDA)이란 무엇인가

EDA(exploratory data analysis)란 결론을 내기 전에 데이터가 어떻게 생겼는지 살펴보는 단계다.

무엇을 보는가

중심 · 산포 · 이상치


왜 하는가

요약 숫자 하나만 보면 뒤에 무엇이 숨어 있는지 알 수 없다.

숫자로 한 번, 그림으로 한 번 본다.

4.3

중심을 나타내는 세 가지 값




치우친 분포에서는 최빈값 · 중앙값 · 평균이 이 순서로 벌어진다

분포가 한쪽으로 치우치면 세 값이 벌어진다. 금액 · 매출 같은 자료는 대개 오른쪽으로 치우쳐, 평균이 중앙값보다 크게 나온다.

이름	무엇인가
평균 mean	모두 더해 개수로 나눈 값. 튀는 값에 크게 흔들린다
중앙값 median	크기순으로 줄 세웠을 때 한가운데 값. 튀는 값에 잘 흔들리지 않는다
최빈값 mode	가장 자주 나온 값. 범주형 자료에 주로 쓴다

평균만으로 충분한 때와 그렇지 않은 때



왼쪽 대칭 분포 · 오른쪽 치우친 분포. 파란 선이 중앙값, 빨간 선이 평균

대칭 분포

평균과 중앙값이 **거의 같다**. 평균 하나로 요약해도 무리가 없다.

치우친 분포

평균이 **오른쪽으로 끌려간다**. 큰 값 몇 개가 평균을 올리므로 중앙값을 함께 봐야 한다.

4.5

평균 하나로 보고하면 생기는 일

듣는 사람은 “평균 얼마” 라는 말을 들으면 **그 정도 값이 가장 많다고** 이해한다. 치우친 분포에서는 그렇지 않다.

듣는 사람의 이해

“대부분의 값이 평균 근처에 몰려 있겠구나”

실제

큰 값 몇 개가 평균을 끌어올려, **대다수는 평균보다 훨씬 작을 수 있다**

그래서 **평균과 중앙값을 함께** 보고, 둘이 크게 벌어지면 **중앙값을 함께 적는다**. “평균 얼마, 다만 절반은 얼마 이하” 처럼 쓴다.

무엇을 보고해야 하는가


데이터가 이렇게 생겼다면	어울리는 값
값들이 고르게 퍼져 있다	평균
한쪽으로 치우쳐 있다 (매출·소득·방문수)	중앙값
큰 값 자체가 중요하다 (총매출 예측)	평균 또는 합계

정답은 없습니다. 다만 **하나만 보고하면** 안 됩니다.
평균과 중앙값이 크게 다르다면, 그 사실 자체가 알려야 할 정보입니다.

4.6

퍼진 정도 — 표준편차

표준편차(standard deviation) 는 값들이 평균에서 **평균적으로** 얼마나 떨어져 있는지를 나타낸다.



평균은 같고 표준편차만 다른 두 분포

평균이 같아도 퍼진 정도는 다를 수 있다. 두 분포의 평균은 모두 100 이다.

표준편차가 **평균보다 크면** 그 평균은 대표값으로 쓰기 어렵다.
값들이 평균에서 그만큼 멀리 흩어져 있다는 뜻이다.

표준편차를 함께 보는 이유

표준편차는 그 평균을 얼마나 믿어도 되는지 알려 준다. 평균과 견주어 보는 것이 요령이다.

표준편차가 평균보다 작다

값들이 평균 근처에 모여 있다.

“보통 이 정도입니다” 라고 말해도 된다.

예 — 배송 일수, 근무 시간

표준편차가 평균보다 크다

값들이 넓게 흩어져 있다.

“보통 이 정도” 라는 말이 성립하지 않는다.

예 — 주문 금액, 매출, 소득

금액 자료는 대개 오른쪽이 길게 늘어져 **표준편차가 평균보다 커진다**. 이럴 때는 평균 대신 **중앙값과 분위수**로 말하는 편이 정확하다.

이상치란 무엇인가

이상치(outlier) 는 다른 값들과 견주어 유난히 크거나 작은 값이다.

왜 문제가 되나

몇 건뿐이어도 **평균을 크게 흔든다**

그래프의 축을 늘려 나머지를 뭉개 버린다

그런데

이상치라고 **다 틀린 값은 아니다**

실제로 일어난 큰 거래일 수도 있다

그래서 순서가 중요하다 — ① 찾는다 → ② 무엇인지 확인한다 → ③ 어떻게 할지 정한다

먼저 — 분위수(quantile)란

값을 크기순으로 줄 세운 뒤, 특정 위치의 값을 가리키는 것이다.



값을 줄 세우고 위치로 나눈다

Q1	아래에서 25% 지점의 값
중앙값	50% 지점 — 정확히 한가운데
Q3	아래에서 75% 지점의 값

IQR 과 상자그림

$IQR = Q3 - Q1$ — 가운데 50%가 차지하는 폭



상자그림의 구조

상자	가운데 50% (Q1 ~ Q3)
빨간 선	중앙값
수염 밖의 점	이상치로 표시된 값

IQR 은 “이상하다”를 판정하지 않는다

IQR 이 하는 일

“다른 값에 비해
크다”를 계산

IQR 이 못 하는 일

“이 값이
잘못되었다”는 판단

금액처럼 오른쪽으로 치우친 데이터에서는 정상적인 큰 거래도 전부 걸린다. **걸렸다고 지우면 실제 매출이 사라진다.**

이상치를 어떻게 할 것인가 — 네 가지

선택	언제	예
고친다	원래 값을 알 수 있을 때	자릿수 오류를 바로잡는다
뺀다	명백한 오류이고 원래 값을 모를 때	단가 0, 수량 음수
남긴다	실제로 일어난 일일 때	대량 주문
따로 본다	그 자체가 관심사일 때	대형 거래만 모아 분석

이상치는 개수가 적어도 평균을 크게 흔든다. 몇 건만 처리해도 평균이 눈에 띄게 움직인다. 어느 쪽을 골랐든 무엇을 몇 건 어떻게 했는지 보고서에 적는다.

이 시간에 다루는 것

노트북에서 하나씩 실행해 본다. 지금 외우지 않아도 된다

하는 일	쓰는 것
중심 보기	<code>.mean()</code> · <code>.median()</code> — 둘을 함께
퍼진 정도	<code>.std()</code>
사분위수	<code>.quantile(0.25)</code> · <code>.quantile(0.75)</code>
한 번에 요약	<code>.describe()</code>
큰 값 · 작은 값 N개	<code>.nlargest(N, '열')</code> · <code>.nsmallest()</code>
분포 그리기	<code>.plot(kind='hist', bins=50)</code>
그룹별 분포	<code>.boxplot(column=, by=)</code>
비율 구하기	<code>(df['열'] < 0).mean() * 100</code>

— 이제 손으로 합니다

노트북 4교시를 엽니다

한글 폰트 설정 → 평균과 중앙값 → 분포 그리기 → 이상치 판단