

— 7교시

오늘 배운 것을 정리하겠습니다

복습과 정리 — 하루를 되짚고, 가져갈 것을 추립니다

7.1

분석의 절차와, 이 시간의 위치

이 시간은 **마지막 단계**에 해당한다. 앞의 일곱 칸을 오늘 다 지나왔다

문제
정의

데이터
이해

전처리

집계·비교

탐색
(EDA)

시각화

관계·
도구

결론·보고

이 단계에서 던지는 질문 — **“그래서 무엇을 다르게 할 것인가”**

오늘 하루, 교시마다 하나씩

교시	남길 것
1교시	행 수는 대상의 수가 아닙니다. 한 행이 무엇인지 먼저 확인합니다
2교시	결측치에는 이유가 있습니다. 그대로 지우면 결과 숫자가 조용히 바뀝니다
3교시	기준선을 무엇으로 잡느냐에 따라 같은 달이 감소도 되고 증가도 됩니다
4교시	평균 뒤에 중앙값이 있습니다. 이상치를 지울지 남길지가 어려운 판단입니다
5교시	같은 데이터로 정반대 인상의 그래프를 만들 수 있습니다. 축은 0부터
6교시	같이 움직인다고 원인은 아닙니다. 도구는 코드를 대신 쓸 뿐입니다
7교시	보고서는 질문·결론·한계·할 일 네 칸입니다

정리

오늘 지나온 길

회사에 가져갈 것을 추려 봅니다

무엇으로 다뤘나

Pandas

표(DataFrame)를 다루는 **표준 라이브러리**

NumPy 는 수치 계산,
Matplotlib · Seaborn 은 그래프

Colab

브라우저에서 파이썬을 돌려 주는 **구글 서비스**

Jupyter Notebook

코드와 결과를 **한 화면**에서 보는 문서
형식

한 문장으로 — **Colab 화면에서 파이썬으로 Pandas 에게 표를 시켰습니다.**

노트북이 편했던 이유

오늘 이렇게 썼습니다

셀 단위로 하나씩 실행했고

코드 **바로 아래에 결과**가 나왔고

엑셀 파일도 불러왔습니다

이런 도구가 아닙니다

전체를 한 번에만 돌리는 것

그래프가 창이 따로 뜨는 것

엑셀을 못 읽는 것

오늘 하루 셀을 하나씩 실행하며 확인한 것이 바로 이 방식이었습니다.

데이터를 불러올 때

CSV 파일

```
pd.read_csv('파일명.csv')
```

엑셀 파일

```
pd.read_excel('파일명.xlsx')
```

날짜 열

```
parse_dates=['주문일']
```

 을 함께 적는다

읽는 것은 모두 **read_** 로 시작합니다. **open_** · **load_** · **import_** 로 시작하는 것은 없습니다.

데이터를 다듬을 때 만나는 것

이름	무엇인가	확인하는 법
결측치	비어 있는 칸	<code>df.isnull().sum()</code> — <code>isna()</code> 와 같음
이상치	다른 값에 비해 유난히 크거나 작은 값	<code>describe()</code> · 상자그림 · IQR
중복값	모든 칸이 똑같은 행	<code>df.duplicated().sum()</code>

비어 있는 것과 튜는 것은 다릅니다. 그리고 **이상치는 항상 지우는 것이 아닙니다** — 오류일 수도, 실제로 일어난 큰 거래일 수도 있습니다.

엑셀에서 하던 일이 그대로

피벗테이블

groupby()

항목별로 묶어서 계산

지역별 매출 합계, 부서별 평균

VLOOKUP

merge()

두 표를 공통 열로 합치기

사번을 기준으로 옆에 붙이기

한편 `sort_values()` 는 정렬, `dropna()` 는 결측치 제거, `rename()` 은 이름 바꾸기 — 묶는 것과는 다른 일입니다.

말하려는 것이 차트를 정한다

말하려는 것	차트
시간에 따른 변화	선 그래프 — 월별 매출 추이
항목 사이의 크기 비교	막대그래프
두 숫자의 관계	산점도
값이 퍼진 모양	히스토그램 · 상자그림

그리고 막대그래프의 세로축은 0부터. **같은 데이터로 정반대 인상을 만들 수 있습니다.**

두 값이 같이 움직이는 정도

상관계수 — -1 에서 +1 사이

+1 에 가깝다

한쪽이 오르면 다른 쪽도 오른다

0 에 가깝다

직선 관계가 약하다

-1 에 가깝다

한쪽이 오르면 다른 쪽은 내린다

평균 · 중앙값은 가운데가 어디인지, 표준편차는 얼마나 퍼져 있는지를 말합니다. 관계를 말하는 것은 상관계수입니다.

결과를 읽을 때 — 오늘 내내 한 이야기

이렇게 말합니다

“상관관계가 높아도

인과관계가 있다고 단정할 수 없다”

이렇게 말하지 않습니다

“상관이 높으니 원인이다”

“평균만 보면 충분하다”

“이상치는 항상 지운다”

오른쪽 셋은 오늘 하루 동안 반례를 직접 봤습니다 — 숨은 원인, 평균 뒤의 중앙값, 실제로 일어난 큰 거래.

한 장으로

Pandas	표를 다루는 라이브러리
read_csv()	파일 불러오기 (엑셀은 read_excel())
Jupyter Notebook	코드와 결과를 한 화면에서, 셀 단위로 실행
isnull() · isna()	결측치 — 비어 있는 값
이상치	유난히 크거나 작은 값 — 항상 지우지 않는다
groupby()	항목별로 묶어서 계산 (피벗테이블)
merge()	두 표를 공통 열로 합치기 (VLOOKUP)
선 그래프	시간에 따른 추이
상관계수	-1 ~ +1, 같이 움직이는 정도
상관 ≠ 인과	같이 움직인다고 원인은 아니다